



清华大学  
Tsinghua University


# A Unified Model for Opinion Target Extraction and Target Sentiment Prediction

---

报告人：史可为、吴冠陞

## 金融+情感分析

社群平台



金融领域平台



主观性文本



## 相关研究

金融词库：中国财经媒体领域的正负面词库

中文情感分析分类模型



# 一、研究背景

## 二、研究方法

## 三、实验

## 四、结论

## 研究背景

基于目标的情感分析 (Target-based sentiment analysis, TBSA)

: 1. 检测意见目标, 2. 并预测意见目标的情绪极性

### 一般方法: 分为两个子任务

- 目标提取
- 检测文本中的意见目标
- 情绪分类
- 预测给定意见目标的情感极性

传统工作: 大部分只针对其中的一个子任务解决。

## 已有的集成解决方案：

- 两个子任务的模型联合训练  
利用一组目标边界标签（例如：B, I, E, S和O）  
和一组情感标签（例如POS, NEG, NEU）  
进行联合训练

### Unified Tagging Scheme:

两个子任务的边界，利用一组专门设计的标签  
（“统一标记方案”）

Input	The	AMD	Turin	Processor	seems	to	always	perform	much	better	than	Intel	.
Joint	O	B	I	E	O	O	O	O	O	O	O	S	O
	O	POS	POS	POS	O	O	O	O	O	O	O	NEG	O
Unified	O	B-POS	I-POS	E-POS	O	O	O	O	O	O	O	S-NEG	O

Table 1: Tagging schemes used in the integrated approaches. “Joint” and “Unified” refers to joint and unified approaches respectively.

## 问题

提出一种更完整的模型来解决这一问题

# A Unified Model for Opinion Target Extraction and Target Sentiment Prediction

unified tagging scheme

本文提出一种端到端的方案，通过一个应用“统一标记方案”的统一模型来完成TBSA。

模型包括两个LSTM：

上层预测统一标签进行初步TBSA

下层通过辅助目标边界预测来指导上层网络提升性能

## 任务定义

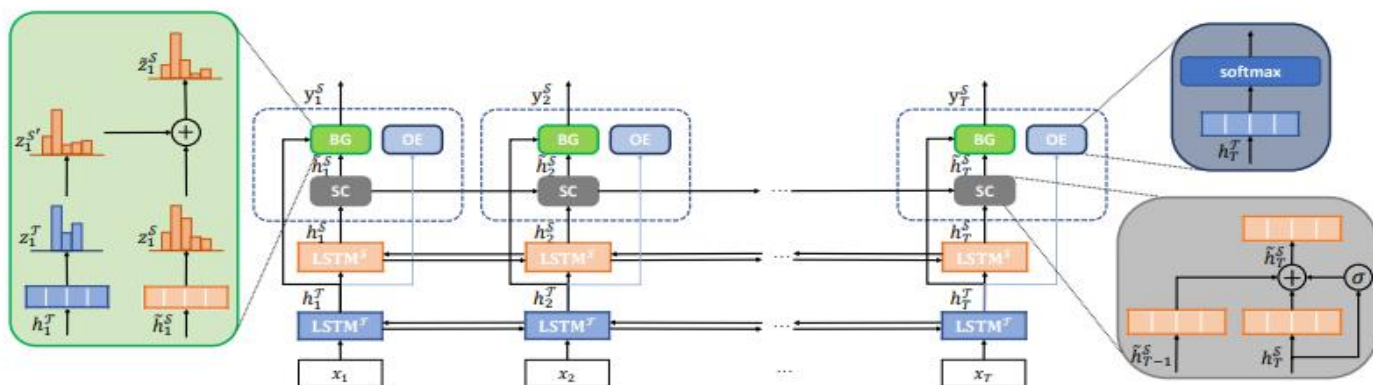
本文提出了一个 Target-Based Sentiment Analysis ( **TBSA** ) 任务作为一个序列标注任务，给定一个序列采用如下标签进行标记：

其中B,I,E,S分别代表一个 **aspect** 的开始、一个 **aspect** 的中间部分、一个 **aspect** 的结尾、和单个 **aspect** ； O 代表该字符不在一个 **aspect** 之内； POS、NEG、NEU 分别代表情感倾向为正向、负向、中性。如下图所示：

Input	The	AMD	Turin	Processor	seems	to	always	perform	much	better	than	Intel	.
Joint	O	B	I	E	O	O	O	O	O	O	O	S	O
	O	POS	POS	POS	O	O	O	O	O	O	O	NEG	O
Unified	O	B-POS	I-POS	E-POS	O	O	O	O	O	O	O	S-NEG	O

## 模型图

针对给定的输入序列  $X = (x_1, \dots, x_T)$ ，我们的目标是输出  $Y^S = (y_1^S, \dots, y_T^S)$ ，其中  $y_i^S \in \mathcal{Y}^S$ 。



Input	The	AMD	Turin	Processor	seems	to	always	perform	much	better	than	Intel	.
Joint	O	B	I	E	O	O	O	O	O	O	O	S	O
	O	POS	POS	POS	O	O	O	O	O	O	O	NEG	O
Unified	O	B-POS	I-POS	E-POS	O	O	O	O	O	O	O	S-NEG	O

低层LSTM: 主要负责目标边界检测，即预测给定的 token 标签

高层LSTM: 主要负责预测标签序列，并以低层LSTM生成的隐含表示作为指导信息

Sentiment Consistency (SC): 情感一致性组件，结合前文特征到当前预测中，保持多词目标的情感依赖

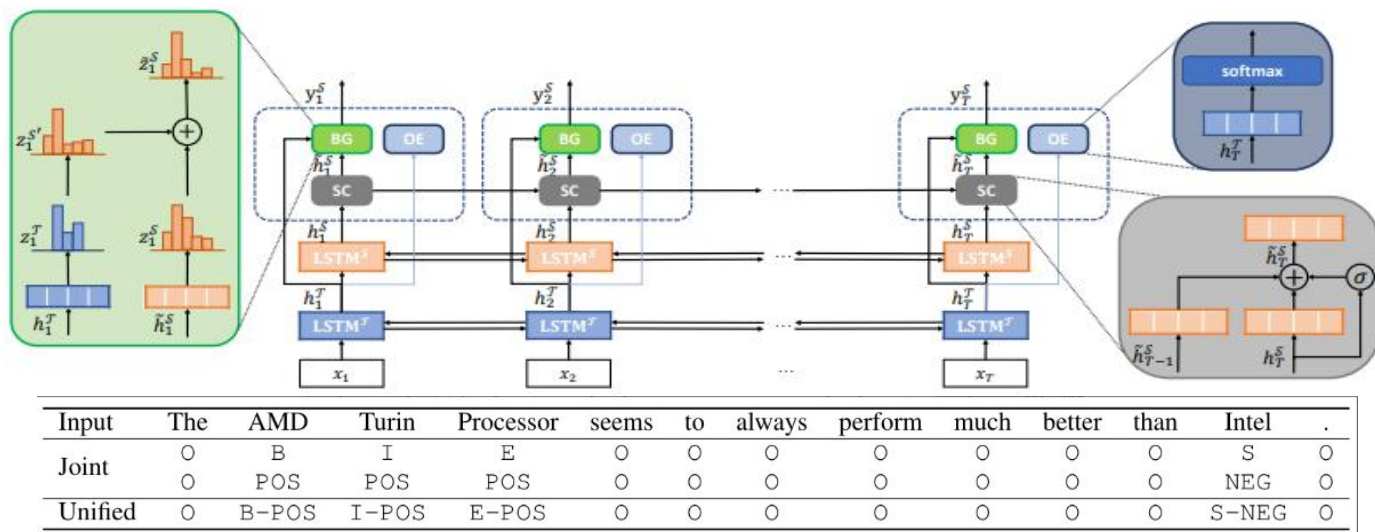
Boundary Guidance (BG): 边界引导组件，从辅助任务提取边界信息指导统一标签预测

Opinion-Enhanced (OE): 观点增强目标词检测组件，判定当前词是否为目标词





# Target Boundary Guided TBSA




- 低层LSTM主要负责预测目标边界，即预测给定的 token 标签  $y^T \in \{B, I, E, S, O\}$
- 高层LSTM预测标签序列，即标签POS/NEG/NEU
- 低层LSTM生成的隐含表示作为高层的指导信息。

$$h_t^T = [\overrightarrow{\text{LSTM}}^T(x_t); \overleftarrow{\text{LSTM}}^T(x_t)],$$

$$h_t^S = [\overrightarrow{\text{LSTM}}^S(h_t^T); \overleftarrow{\text{LSTM}}^S(h_t^T)], \quad t \in [1, T]$$

# Target Boundary Guided TBSA

- 边界标签和统一标签的概率分数：



$$z_t^T = \mathbf{p}(y_t^T | x_t) = \text{Softmax}(\mathbf{W}^T h_t^T)$$


$$z_t^S = \mathbf{p}(y_t^S | h_t^T) = \text{Softmax}(\mathbf{W}^S h_t^S)$$

$z_t^T \in \mathbb{R}^{|y^T|}$  代表着该 token 作为 boundary tag 的概率

$z_t^S \in \mathbb{R}^{|y^S|}$  在前者的基础上计算其附加情感倾向的概率

# Target Boundary Guided TBSA

- Boundary guided transition matrix



$$\mathbf{W}^{tr} \in \mathbb{R}^{|\mathcal{Y}^T| \times |\mathcal{Y}^S|}$$


$$\mathbf{W}_{i,j}^{tr} = \begin{cases} \frac{1}{|\mathcal{B}_i|}, & \text{if } j \in \mathcal{B}_i \\ 0, & \text{Otherwise} \end{cases}$$

这里的  $\mathcal{B}_i$  是在给定 boundary tag  $i$  的情况下, unified tag 的合理输出, 比如 B 对应着 B-POS、B-NEG、B-NEU。最后 transition-based sentiment score  $z_t^{S'} \in \mathbb{R}^{|\mathcal{Y}^S|}$  计算方式如下:

$$z_t^{S'} = (\mathbf{W}^{tr})^\top z_t^T$$

# Target Boundary Guided TBSA

如果  $z_t^T$  差不多满足均匀分布的情况下，那么  $z_t^{S'}$  也会差不多满足均匀分布



- Proportion scor  $\alpha_t \in \mathbb{R}$  :

$$c_t = (z_t^T)^\top z_t^T$$


$$\alpha_t = \epsilon c_t$$

- Final scores

$$\tilde{z}_t^S = \alpha_t z_t^{S'} + (1 - \alpha_t) z_t^S$$

# Maintaining Sentiment Consistency

Input	The	AMD	Turin	Processor	seems	to	always	perform	much	better	than	Intel	.
Joint	0	B	I	E	0	0	0	0	0	0	0	S	0
	0	POS	POS	POS	0	0	0	0	0	0	0	NEG	0
Unified	0	B-POS	I-POS	E-POS	0	0	0	0	0	0	0	S-NEG	0



- 从当前和之前步的特征中预测当前统一标签（使用门机制）：


$$\tilde{h}_t^S = g_t \odot h_t^S + (1 - g_t) \odot \tilde{h}_{t-1}^S$$

$$g_t = \sigma(\mathbf{W}^g h_t^S + \mathbf{b}^g)$$

- 之前的特征也会被考虑到当前预测中，避免同一目标中出现不同的情感。

## Auxiliary Target Word Detection

该部分的主要作用就是，确保情感词和 aspect 同时出现，采用如下计算方式：



$$z_t^O = \text{Softmax}(\mathbf{W}^O h_t^T)$$

$$y_t^O = \arg \max_y z_t^O$$



## 实验部分

### 数据集

来源：

1. SemEval ABSA Challenges
2. 推特数据库

DL：笔记型电脑产品评价

DR：2014 – 2016餐厅数据

DT：2013年收集的推特推文数据

Dataset	Train	Dev	Test	Total	
$\mathbb{D}_L$	# POS	883	104	339	1326
	# NEG	754	106	130	990
	# NEU	404	46	165	615
$\mathbb{D}_R$	# POS	2337	270	1524	4131
	# NEG	942	93	500	1535
	# NEU	614	50	263	927
$\mathbb{D}_T$	# POS	-			692
	# NEG	-			263
	# NEU	-			2244

Table 2: Statistics of the datasets.



## 对比模型

CRF– Conditional Random Fields 条件随机场 (Mitchell 2013)

CRF–pipeline:

CRF–joint : joint tagging scheme

CRF–unified : unified tagging scheme

NN–CRF 增强的CRF 模型, 利用NN进行特征提取 (Zhang 2015)

NN– CRF–pipeline:

NN– CRF–joint : joint tagging scheme

NN– CRF–unified : unified tagging scheme

HAST–TNet (Li等人)

目标检测 + 情感分类 两个模型的 Pipeline





## 对比模型

LSTM-unified

标准 LSTM模型: unified tagging scheme

LSTM- CRF

LSTM+CRF decoding 层

LM-LSTM-CRF

Language mode 增强LSTM-CRF模型



## 实验结果

$$F_1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

评估指标：standard precision (P)、recall (R) 和F1 Score

Model		$\mathbb{D}_L$			$\mathbb{D}_R$			$\mathbb{D}_T$		
		P	R	F1	P	R	F1	P	R	F1
Existing Baselines	CRF-joint	57.38	35.76	44.06	60.00	48.57	53.68	43.09	24.67	31.35
	CRF-unified	59.27	41.86	49.06	63.39	57.74	60.43	48.35	19.64	27.86
	NN-CRF-joint	55.64	34.48	45.49	61.56	50.00	55.18	44.62	35.84	39.67
	NN-CRF-unified	58.72	45.96	51.56	62.61	60.53	61.56	46.32	32.84	38.36
Pipeline Baselines	CRF-pipeline	59.69	47.54	52.93	52.28	51.01	51.64	42.97	25.21	31.73
	NN-CRF-pipeline	57.72	49.32	53.19	60.09	61.93	61.00	43.71	37.12	40.06
	HAST-TNet	56.42	54.20	55.29	62.18	73.49	67.36	46.30	49.13	47.66
Unified Baselines	LSTM-unified	57.91	46.21	51.40	62.80	63.49	63.14	51.45	37.62	43.41
	LSTM-CRF-1	58.61	50.47	54.24	66.10	66.30	66.20	51.67	44.08	47.52
	LSTM-CRF-2	58.66	51.26	54.71	61.56	67.26	64.29	53.74	42.21	47.26
	LM-LSTM-CRF	53.31	59.4	56.19	68.46	64.43	66.38	43.52	52.01	47.35
OURS	Base model	60.00	46.85	52.61	61.48	66.16	63.73	53.02	41.47	46.50
	Base model + <b>BG</b>	58.58	50.63	54.31	67.51	66.42	66.96	52.26	43.84	47.66
	Base model + <b>BG</b> + <b>SC</b>	58.95	53.00	55.81	63.95	69.65	66.68	53.12	43.60	47.79
	Base model + <b>BG</b> + <b>OE</b>	63.43	49.53	55.62	62.85	66.77	65.22	53.10	43.50	47.78
	Full model	61.27	54.89	<b>57.90<sup>§,‡</sup></b>	68.64	71.01	<b>69.80<sup>§,‡</sup></b>	53.08	43.56	<b>48.01<sup>‡</sup></b>

## 消融研究

base model中辅助LSTM预测的边界信息对性能有所提升，加入BG后，由于边界限制，提升更加明显，SC和OE如果只是单独加入，则另外的组件信息无法提供指导，有时性能反而下降。

OURS	Base model	60.00	46.85	52.61	61.48	66.16	63.73	53.02	41.47	46.50
	Base model + <b>BG</b>	58.58	50.63	54.31	67.51	66.42	66.96	52.26	43.84	47.66
	Base model + <b>BG</b> + <b>SC</b>	58.95	53.00	55.81	63.95	69.65	66.68	53.12	43.60	47.79
	Base model + <b>BG</b> + <b>OE</b>	63.43	49.53	55.62	62.85	66.77	65.22	53.10	43.50	47.78
	Full model	61.27	54.89	57.90 <sup>§,‡</sup>	68.64	71.01	69.80 <sup>§,‡</sup>	53.08	43.56	48.01 <sup>‡</sup>

## 例子

Input	Base model		Base model + BG		Full model	
	Target	Complete	Target	Complete	Target	Complete
1. And the fact that it comes with an [ <i>i5 processor</i> ] <sub>POS</sub> definitely speeds things up	<i>i5 processor</i>	[processor] <sub>POS</sub> (X)	<i>i5 processor</i>	[i5 processor] <sub>POS</sub>	<i>i5 processor</i>	[i5 processor] <sub>POS</sub>
2. There were small problems with [ <i>mac office</i> ] <sub>NEG</sub> .	<i>mac office</i>	[mac] <sub>NEG</sub> (X)	<i>mac office</i>	[mac office] <sub>NEG</sub>	<i>mac office</i>	[mac office] <sub>NEG</sub>
3. The [ <i>teas</i> ] <sub>POS</sub> are great and all the [ <i>sweets</i> ] <sub>POS</sub> are homemade	<i>teas, sweets</i>	[teas] <sub>POS</sub> , [sweets] <sub>POS</sub>	<i>teas, sweets, homemade</i> (X)	[teas] <sub>POS</sub> , [sweets] <sub>POS</sub> , [homemade] <sub>POS</sub> (X)	<i>teas, sweets</i>	[teas] <sub>POS</sub> , [sweets] <sub>POS</sub>
4. I love the [ <i>form factor</i> ] <sub>POS</sub>	NONE	NONE	NONE	NONE	<i>form factor</i>	[form factor] <sub>POS</sub>
5. I blame the [ <i>Mac OS</i> ] <sub>NEG</sub> .	<i>Mac OS</i>	[Mac <sub>NEG</sub> OS <sub>NEU</sub> ] (X)	<i>Mac OS</i>	[Mac <sub>NEG</sub> OS <sub>POS</sub> ] (X)	<i>Mac OS</i>	[Mac OS] <sub>NEG</sub>
6. Also, I personally wasn't a fan of the [ <i>portobello and asparagus mole</i> ] <sub>NEG</sub> .	<i>portobello and asparagus mole</i>	[portobello <sub>NEG</sub> and <sub>NEG</sub> asparagus <sub>NEG</sub> mole <sub>NEU</sub> ] (X)	<i>portobello and asparagus mole</i>	[portobello <sub>NEG</sub> and <sub>NEG</sub> asparagus <sub>NEU</sub> mole <sub>NEU</sub> ] (X)	<i>portobello and asparagus mole</i>	[portobello and asparagus mole] <sub>NEG</sub>

base可以预测目标边界，但目标情感错误，两个LSTM没有准确预测边界信息，BG可以准确预测边界信息，但可能会存在边界检测错误，OE可以解决这个问题，SC针对一些较长的目标词也可准确识别。

## 总结

本文的模型中，三个组件起到了很好的辅助作用，只加入BG时由于增加了边界信息，准确率会上升，但可能会从低层LSTM中获取错误的边界信息，检测边界错误，OE与SC的加入会改善这个问题，但单独加入时有时性能反而会下降，其中原因可能是OE会提供准确的目标词与非目标词给SC进行情感依赖处理，而SC会控制同一目标词中相同的情感信息，后续可以验证SC与OE的相互关系。